Analisis Sentimen Ulasan Pengguna CamScanner Mobile pada Google Play Store Menggunakan Algoritma Naive Bayes

Dikembangkan oleh :

Muh. Furqan Aprilian Putra Muslihat

A. Pengumpulan dan Pelabelan Data

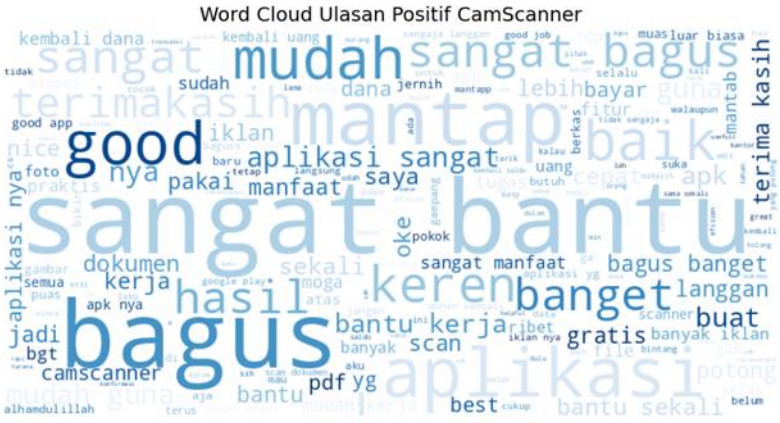
Mengumpulkan 2.000 ulasan pengguna CamScanner Mobile dari Google Play Store menggunakan teknik web scraping dengan pustaka google-play-scraper berbasis Python pada Google Colab. Ulasan dengan rating 4–5 dikategorikan sebagai sentimen positif, rating 1–2 sebagai sentimen negatif, sedangkan rating 3 dieliminasi. Hasilnya diperoleh 1.949 data valid, terdiri dari 1.607.

B. Text Preprocessing

Tahapan Pemrosesan	Bentuk Hasil Teks
Data Mentah	cuman mindahin halaman aja sampe harus berlangganan dulu lohh, parah bangettt
Cleaning dan Case Folding	cuman mindahin halaman aja sampe harus berlangganan dulu lohh parah bangettt
Filtering	cuman mindahin halaman aja sampe berlangganan dulu lohh parah bangettt
Stemming	cuman mindahin halaman aja sampe langgan dulu lohh parah bangettt
Tokenizing	cuman,mindahin,halaman,aja,sampe,langgan,dulu,lohh,parah,bangettt

Melakukan preprocessing teks secara bertahap yang meliputi cleaning, case folding, filtering (stopwords removal), stemming menggunakan pustaka Sastrawi, dan tokenizing. Tahapan ini dilakuka untuk membersihkan serta menyeragamkan data ulasan sebelum digunakan dalam proses klasifikasi

C. Visualisasi WordCloud



Kumpulan kata yang paling sering muncul dari pengguna yang merasa puas (rating 4 dan 5)

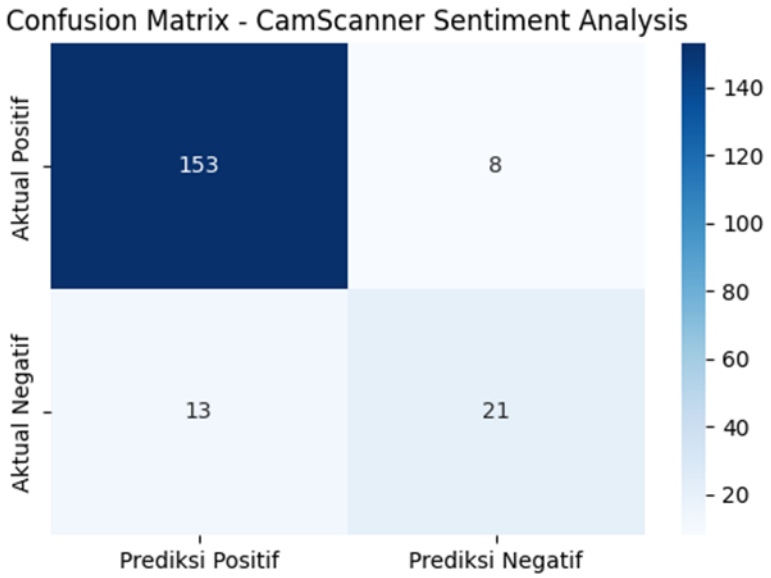


Kumpulan kata-kata yang dominan pada ulasan negatif memberikan gambaran mengenai pengalaman pengguna yang kurang memuaskan.

D. Pemodelan Naïve Bayes

Membangun model klasifikasi menggunakan algoritma Multinomial Naive Bayes dengan pembagian data 90% sebagai data latih dan 10% sebagai data uji. Dari 1.949 data valid, sebanyak 1.754 data digunakan untuk pelatihan dan 195 data untuk pengujian

E. Evaluasi Model



Berdasarkan pemetaan Confusion Matrix pada Gambar 6, rincian hasil prediksi model Naïve Bayes terhadap data uji adalah sebagai berikut:

1. True Positive (TP = 153): Terdapat 153 ulasan yang secara aktual bersentimen positif dan berhasil diprediksi secara benar sebagai kelas positif oleh model.
2. False Negative (FN = 8): Terdapat 8 ulasan yang secara aktual bersentimen positif, namun salah diprediksi oleh model sebagai kelas negatif.
3. False Positive (FP = 13): Terdapat 13 ulasan yang secara aktual bersentimen negatif, namun salah diprediksi oleh model sebagai kelas positif.
4. True Negative (TN = 21): Terdapat 21 ulasan yang secara aktual bersentimen negatif dan berhasil diprediksi secara benar sebagai kelas negatif oleh model.

Dari nilai TP, TN, FP, dan FN tersebut, dilakukan kalkulasi performa model menggunakan empat metrik utama evaluasi:

1. Accuracy

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{153 + 21}{195} = \frac{174}{195} \approx 0.892308 \quad (89.23\%)$$

2. Precision

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{153}{153 + 13} = \frac{153}{166} \approx 0.921687 \quad (92.17\%)$$

3. Recall

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{153}{153 + 8} = \frac{153}{161} \approx 0.950311 \quad (95.03\%)$$

4. F1-Score

$$\text{F1-Score} = 2 \times \left(\frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}\right) = 2 \times \frac{0.921687 \times 0.950311}{0.921687 + 0.950311} \approx 0.935780 \quad (93.58\%)$$

Parameter Evaluasi	Nilai Desimal	Presentase
Accuracy	0.892308	89.23%
Precision	0.921687	92.17%
Recall	0.950311	95.03%
F1-Score	0.935780	93.58%

Hasil evaluasi menunjukkan bahwa model Multinomial Naive Bayes mampu melakukan klasifikasi sentimen dengan performa yang baik. Analisis juga menunjukkan bahwa ulasan positif terutama berkaitan dengan kualitas pemindaian dan kemudahan pengelolaan dokumen, sedangkan ulasan negatif banyak berkaitan dengan kendala teknis, penyimpanan, iklan, dan layanan berlangganan.

Deskripsi Proyek :

Teknologi yang Digunakan :